M2: DATA QUALITY REPORT

Exploratory Data Analysis (KMTI21133) · Bobot 10% · Dikumpulkan pada pertemuan 5

Nama tim	Triaxis
Anggota dan peran	M. Radifah Hibatillah: Mengerjakan No 2&3 Anastasya N.A: 1&5 Klaudia Weda: 4
Judul proyek	Membersihkan Data dengan Alasan
Pertanyaan payung	Bagaimana pola penjualan koperasi pada Agustus–November 2025 menurut kategori produk, waktu, dan metode pembayaran, dan apakah pola itu berhubungan dengan kepuasan anggota (rating layanan)? **Pertanyaan turunan:** 1. **Kategori:** Kategori dan produk apa yang menyumbang omzet terbesar, dan apakah perbedaan rata-rata nilai belanja antar kategori (misalnya Makanan Rp40.698 dibanding ATK Rp15.407) nyata secara statistik? *Kolom: kategori, nama_produk, total_bayar.* 2. **Waktu dan metode bayar:** Apakah omzet dan jumlah transaksi berubah dari bulan ke bulan, dan apakah pilihan metode pembayaran (tunai, QRIS, transfer, saldo koperasi) berbeda menurut kategori atau jam transaksi? *Kolom: tanggal_transaksi (bulan, hari, jam), metode_bayar, kategori.* 3. **Kepuasan:** Apakah rating layanan berbeda menurut kasir, kategori, metode bayar, atau besar diskon, dengan rating kosong diperlakukan secara eksplisit? *Kolom: rating_layanan, kasir, kategori, metode_bayar, diskon_persen.*
Dataset	transaksi_koperasi_2025.csv (1.543 baris, 16 kolom; 1 Agustus–28 November 2025)
Tautan repositori	https://github.com/RadifHibatillah/praktikum03_EDA_NANA_RADIF_WEDA/invitations
Tanggal laporan	19 Oktober 2026

1. Ringkasan

Dataset transaksi_koperasi_2025.csv memuat 1.543 baris dan 16 kolom; satu baris adalah satu item transaksi koperasi pada 1 Agustus–28 November 2025, melibatkan 259 anggota, 18 produk, dan 4 kasir. Tiga masalah terbesar: (1) total_bayar tidak sama dengan jumlah × harga × (1 − diskon) pada 52 baris, selalu berupa kelipatan 0,5×, 2×, atau 10×, sehingga satu nilai bisa mencapai Rp800.000 padahal transaksi wajar berkisar Rp500–Rp96.000; (2) angka mustahil dan penanda yang menyamar sebagai data, yaitu jumlah nol atau negatif (29 baris), diskon di luar 0–10% (9 baris), dan rating −999 (49 baris) yang menarik rata-rata rating menjadi −27,7; (3) 43 baris ganda serta ejaan yang terpecah (18 penulisan untuk 5 kategori, 318 penulisan untuk 259 anggota). Keputusan paling berpengaruh adalah menghitung ulang total_bayar dari komponennya, karena harga satuan tetap per produk; bersama deduplikasi, ini menurunkan total omzet dari Rp50,72 juta menjadi Rp42,85 juta (−15,5%) dan simpangan baku total_bayar dari Rp46.834 menjadi Rp20.219. Nilai kosong sengaja tidak diisi: berat_kg (22,8%), saldo_simpanan (10,5%), dan catatan_kasir (67,3%). Hasil akhirnya 1.500 baris dan 24 kolom tanpa duplikat; data layak untuk analisis penjualan dan pembayaran, tetapi analisis berat dan saldo hanya berlaku pada sebagian baris dan beberapa asumsi koreksi perlu dikonfirmasi ke pemilik data.

2. Data dan cara memeriksanya

2.1 Asal data

Butir	Isi
Nama sumber	Dari Elena, Berkas: transaksi_koperasi_2025.csv
Tautan atau instansi	https://elena.nurulfikri.ac.id/mod/folder/view.php?id=62363
Tanggal pengambilan	19 Oktober 2026
Lisensi atau nomor izin	-
Kalimat sitasi	[Hilmy Abidzar Tawakal, S.T., M.Kom] . (2025). *transaksi_koperasi_2025.csv* [Dataset]. KMTI21133 Exploratory Data Analysis, e-Learning STT Nurul Fikri. https://elena.nurulfikri.ac.id/mod/folder/view.php?id=62363

2.2 Ukuran dan cakupan

Berkas mentah berisi 1.543 baris dan 16 kolom: id_transaksi, tanggal_transaksi, id_anggota, nama_produk, kategori, satuan, jumlah, harga_satuan, diskon_persen, total_bayar, metode_bayar, kasir, saldo_simpanan, berat_kg, rating_layanan, dan catatan_kasir. Satuan amatan adalah satu item transaksi: satu id_transaksi berisi satu produk (tidak ada keranjang multi-produk). Rentang waktu mencakup 1 Agustus 2025 07:09 sampai 28 November 2025 16:25, dengan jam transaksi 07.00–17.59 dan 357–413 baris per bulan. Data memuat 259 anggota (rata-rata 5,8 transaksi per anggota; minimum 1, maksimum 16), 18 produk yang masing-masing berharga tetap, 5 kategori, 4 kasir, dan 4 metode pembayaran. Setelah pembersihan tersisa 1.500 baris (1.493 id_transaksi unik; 7 baris tanpa id) dan 24 kolom.

2.3 Cara pemeriksaan

Pemeriksaan dijalankan dengan Python (pandas dan scipy.stats), dengan semua kolom dibaca sebagai teks dahulu agar tidak ada nilai yang diam-diam berubah. Yang diperiksa: format dan tipe tiap kolom (dua format tanggal, awalan “Rp” pada nominal); frekuensi nilai kategorikal termasuk spasi dan kapitalisasi; nilai penanda seperti -999, “-”, “null”, “N/A”; duplikat persis dan duplikat menurut id_transaksi; aturan bisnis (total_bayar = jumlah × harga × (1 − diskon), jumlah > 0, diskon 0–100%, satu harga dan satu satuan per produk, tanggal dalam rentang 2025); serta pola kekosongan dengan uji chi-kuadrat dan Mann-Whitney terhadap kategori, kasir, metode bayar, bulan, dan jumlah. Pemeriksaan yang belum dapat dilakukan: pencocokan dengan sumber asli (struk atau pembukuan) dan daftar anggota resmi, karena tidak tersedia; verifikasi makna serta satuan berat_kg dan saldo_simpanan, karena tidak ada kamus data; dan uji MCAR formal (Little), yang tidak dijalankan karena kolom campuran numerik dan kategorikal.

3. Temuan kualitas data

Dimensi	Kolom	Masalah	Jumlah	Keparahan	Keputusan
Validitas	total_bayar	Tidak sama dengan jumlah × harga × (1 − diskon): kelipatan 0,5× (20), 2× (12), 10× (20)	52 baris (3,5%)	Tinggi	Hitung ulang (Keputusan 1)
Validitas	jumlah	Bernilai nol (11) dan negatif (18)	29 baris (1,9%)	Tinggi	Pulihkan dari total_bayar (Keputusan 2)

Dimensi	Kolom	Masalah	Jumlah	Keparahan	Keputusan
Validitas	diskon_persen	Di luar {0, 5, 10}: −20 (6), 110 (1), 150 (2)	9 baris (0,6%)	Sedang	Pulihkan dari total_bayar (Keputusan 2)
Keunikan	id_transaksi	ID ganda: 24 baris identik persis, 19 baris beda hanya kapitalisasi kasir atau catatan_kasir	43 baris kelebihan (2,8%)	Tinggi	Satu baris per ID (Keputusan 3)
Kelengkapan	id_transaksi	ID kosong	7 baris (0,5%)	Rendah	Dibiarkan (Keputusan 7)
Konsistensi	kategori	18 penulisan untuk 5 kategori (spasi, kapital, “Minumam”, “Alat Tulis” = ATK)	121 sel diubah (7,8%)	Tinggi	Seragamkan (Keputusan 4)
Konsistensi	id_anggota	Spasi di ujung nilai: 318 penulisan untuk 259 anggota	65 sel (4,2%)	Tinggi	Buang spasi (Keputusan 4)
Konsistensi	metode_bayar	13 penulisan untuk 4 metode (kapital, spasi)	95 sel kapital, 36 sel spasi	Sedang	Seragamkan (Keputusan 4)
Konsistensi	kasir	8 penulisan untuk 4 kasir (kapital)	19 sel (1,2%)	Rendah	Seragamkan (Keputusan 4)
Konsistensi	tanggal_transaksi	Dua format: ISO (1.236) dan DD/MM/YYYY (307)	307 baris (19,9%)	Sedang	Urai ke datetime (Keputusan 6)
Konsistensi	total_bayar	Dua format: angka polos dan teks “Rp 18.000”	250 baris (16,2%)	Sedang	Ubah ke angka (Keputusan 6)
Validitas	rating_layanan	Penanda −999 menyamar sebagai angka	49 baris (3,2%)	Tinggi	Jadikan kosong (Keputusan 5)
Kelengkapan	metode_bayar	Placeholder “-”, “null”, “N/A”, “tidak diketahui”	28 baris (1,8%)	Sedang	Jadikan kosong (Keputusan 5)
Kelengkapan	berat_kg	Kosong: Jasa dan Pulsa 100%, ATK 16%, makanan dan minuman 0%	351 sel (22,7%)	Sedang	Dibiarkan kosong (Keputusan 7)
Kelengkapan	saldo_simpanan	Kosong tanpa pola yang terlihat	159 sel (10,3%)	Sedang	Dibiarkan kosong (Keputusan 7)
Kelengkapan	catatan_kasir	Kosong; berarti tidak ada catatan	1.044 sel (67,7%)	Rendah	Dibiarkan kosong (Keputusan 7)

Dimensi	Kolom	Masalah	Jumlah	Keparahan	Keputusan
Akurasi	berat_kg	Rata-rata per produk nyaris sama (1,41–1,71 kg) dan berkorelasi dengan jumlah (r = 0,67), bukan berat produk	Seluruh kolom	Sedang	Tidak diubah (Keputusan 8)
Akurasi	kategori	Fotokopi A4 (layanan) masuk ATK	62 baris	Rendah	Tidak diubah (Keputusan 8)
Akurasi	catatan_kasir	"Promo mingguan" tidak sejalan dengan diskon (58 dari 62 berdiskon 0%)	62 baris	Rendah	Tidak diubah (Keputusan 8)

3.1 Pola nilai kosong

Kolom	Persen kosong	Dugaan	Dasar dugaan
berat_kg	22,8%	MAR	Terbukti dari data: kosong pada 100% baris Jasa dan Pulsa (tidak ada barang untuk ditimbang), 0% pada Makanan dan Minuman, dan pada ATK hanya muncul bila jumlah ≤ 2 (51 dari 94 baris ATK dengan jumlah 1–2 kosong; tidak ada yang kosong bila jumlah ≥ 3; Mann-Whitney $p < 0,001$). Tidak bergantung pada kasir ($p = 0,94$) atau metode bayar ($p = 0,64$). Mengapa ATK berjumlah kecil tidak ditimbang tidak dapat diketahui dari data.
saldo_simpanan	10,5%	MCAR (dugaan, tidak dapat dibuktikan)	Tidak berhubungan dengan kategori ($p = 0,62$), kasir (0,59), metode bayar (0,23), bulan (0,33), produk (0,97), jumlah (0,09), maupun total_bayar (0,22). Tidak adanya hubungan pada variabel yang teramati tidak membuktikan MCAR; bila saldo kosong karena saldo anggota nol atau rendah, polanya MNAR.
catatan_kasir	67,3%	MNAR (struktural)	Kolom teks bebas yang diisi kasir hanya bila ada hal khusus, sehingga kosong berarti "tidak ada catatan", bukan hilang. Kosongnya bergantung pada keputusan kasir yang tidak tercatat (ATK 60% kosong, Pulsa 74%, $p = 0,027$). Penyebabnya tidak dapat dibuktikan dari data.

Persentase dihitung pada 1.500 baris setelah pembersihan. rating_layanan (3,1%), metode_bayar (1,9%), dan id_transaksi (0,5%) berada di bawah 5% sehingga tidak dibahas di sini.

4. Keputusan pembersihan dan alasannya

Keputusan tim

Keputusan 1

Masalah	Kolom total_bayar tidak sama dengan jumlah × harga_satuan × (1 − diskon) pada 52 baris (setelah Keputusan 2): 20 baris setengah dari seharusnya, 12 baris dua kali, 20 baris sepuluh kali.
Dugaan pola	Bukan kekosongan, melainkan galat pencatatan. Selalu kelipatan bersih (0,5×, 2×, 10×), mengarah ke salah ketik atau salah kali, bukan gangguan acak.
Keputusan	total_bayar dihitung ulang sebagai jumlah × harga_satuan × (1 − diskon/100). Nilai lama disimpan di kolom total_bayar_asli dan baris ditandai total_dikoreksi = True.
Alasan	Setiap produk hanya punya satu harga satuan (18 produk, 18 harga) dan jumlah selalu 1–8, sehingga total yang benar dapat ditentukan tegas. Kelipatan 10× pada transaksi 2 unit berarti 20 unit, di luar rentang 1–8 pada seluruh baris lain. Kelipatan 0,5× pada 5 unit berarti 2,5 unit, mustahil untuk barang satuan.
Alternatif ditolak	(a) Mempertahankan total_bayar dan mengubah jumlah agar cocok: ditolak karena menghasilkan jumlah pecahan atau di atas 8. (b) Membuang 52 baris: ditolak karena kolom lainnya lengkap dan transaksinya nyata; membuangnya menghilangkan data yang bisa dipulihkan.
Dampak	52 baris dikoreksi (3,5%). Rata-rata total_bayar turun dari Rp32.872 menjadi Rp28.568 dan maksimum dari Rp800.000 menjadi Rp96.000 (Bagian 5.2). Koreksi saja menurunkan omzet Rp6,49 juta.

Keputusan 2

Masalah	jumlah bernilai nol (11 baris) dan negatif (18 baris); diskon_persen bernilai −20 (6), 110 (1), dan 150 (2).
Dugaan pola	Galat entri yang informasinya dapat dipulihkan dari kolom lain (total_bayar); bukan hilang acak.
Keputusan	jumlah negatif diubah menjadi nilai mutlaknya; jumlah nol dihitung dari total_bayar ÷ (harga × (1 − diskon)); diskon tak sah diganti satu-satunya tingkat sah (0, 5, 10) yang cocok dengan total_bayar. Baris ditandai jumlah_dikoreksi atau diskon_dikoreksi.
Alasan	Pada 16 dari 18 baris negatif, total_bayar sama persis dengan |jumlah| × harga × (1 − diskon), jadi yang salah hanya tanda minus (dua sisanya total_bayar-nya sendiri salah dan ditangani di Keputusan 1). Pada 11 baris nol, hitung balik selalu menghasilkan bilangan bulat 1–8. Untuk 9 baris diskon tak sah, tepat satu tingkat sah cocok dengan total: 110 menjadi 10, 150 menjadi 0, −20 menjadi 0 (5 baris) atau 5 (1 baris).
Alternatif ditolak	(a) Membuang 38 baris: ditolak karena informasi pemulihannya tersedia. (b) Mengisi jumlah dengan median (4): ditolak karena bertentangan dengan total_bayar yang tercatat dan menciptakan angka yang tidak pernah terjadi.
Dampak	29 sel jumlah dan 9 sel diskon dikoreksi; tidak ada baris hilang. Rentang jumlah dari −8…8 menjadi 1…8; rata-rata jumlah bergeser dari 4,12 menjadi 4,24.

Keputusan 3

Masalah	43 baris kelebihan pada 42 id_transaksi (41 ID muncul 2 kali, 1 ID 3 kali). 24 baris identik persis; 19 baris berbeda hanya pada kapitalisasi nama kasir atau isi catatan_kasir.
Dugaan pola	Bukan kekosongan; rekaman ganda dari sistem atau entri ulang.
Keputusan	Satu baris dipertahankan per id_transaksi setelah nama kasir diseragamkan; bila ada beda, dipilih baris yang catatan_kasir-nya terisi. 7 baris tanpa id tidak dianggap duplikat.
Alasan	Pada semua 42 ID ganda, setiap kolom selain catatan_kasir identik setelah kasir diseragamkan (tanggal, anggota, produk, jumlah, total, saldo, berat sama), jadi bukan dua transaksi berbeda yang kebetulan berbagi ID. Memilih baris bercatatan menjaga informasi pada 4 ID yang catatannya berbeda.
Alternatif ditolak	drop_duplicates() pada seluruh kolom: ditolak karena hanya menangkap 24 baris dan meloloskan 19 duplikat yang berbeda huruf (“rina” vs “Rina”); karena itu penyeragaman dikerjakan sebelum deduplikasi. Mempertahankan kemunculan pertama: ditolak karena membuang catatan pada 4 ID.
Dampak	1.543 menjadi 1.500 baris (−2,8%). Omzet turun Rp1,38 juta (2,7%) yang sebelumnya terhitung dua kali.

Keputusan 4

Masalah	Penulisan tidak seragam: kategori 18 penulisan untuk 5 kategori; id_anggota 318 penulisan untuk 259 anggota (spasi); metode_bayar 13 penulisan untuk 4 metode; kasir 8 penulisan untuk 4 orang.
Dugaan pola	Tidak berlaku (inkonsistensi, bukan kekosongan).
Keputusan	Spasi di ujung dibuang; kapitalisasi dibakukan lewat peta manual (Lampiran B); “Minumam” menjadi Minuman; “Alat Tulis” digabung ke ATK.
Alasan	“Alat Tulis” memuat empat produk yang persis sama dengan ATK (Buku Tulis, Fotokopi A4, Map Plastik, Pulpen Hitam) dan tidak ada produk lain di bawahnya, sehingga keduanya satu kategori. “Minumam” adalah salah ketik; produknya (teh, air mineral, kopi, susu) di baris lain selalu Minuman. Spasi membuat 59 anggota tampak sebagai anggota ganda.
Alternatif ditolak	Mempertahankan “Alat Tulis” sebagai kategori terpisah: ditolak karena tidak ada produk yang membedakannya; kategori ATK akan terpecah menjadi 272 dan 41 baris dan perbandingan antar kategori menyesatkan.
Dampak	Kategori 18 menjadi 5, metode 13 menjadi 4 (ditambah kosong), kasir 8 menjadi 4, anggota 318 menjadi 259. Tidak ada baris hilang.

Keputusan 5

Masalah	rating_layanan bernilai −999 pada 49 baris (3,2%); metode_bayar berisi “-”, “null”, “N/A”, atau “tidak diketahui” pada 28 baris (1,8%).
Dugaan pola	MCAR (dugaan): kekosongan rating tidak berhubungan dengan kategori ($p = 0,24$), kasir (0,47), atau metode bayar (0,52). Metode_bayar tidak diuji terpisah karena jumlahnya kecil.
Keputusan	Seluruhnya diubah menjadi kosong (NaN) dan tidak diisi.
Alasan	−999 adalah kode “tidak ada penilaian”, bukan nilai rating; bila dibiarkan, rata-rata rating menjadi −27,7 padahal sebenarnya 4,14. Rating adalah opini pelanggan, sehingga nilai yang diisi sendiri berarti menciptakan penilaian yang tidak pernah diberikan.

Alternatif ditolak	(a) Imputasi rata-rata (4,14): ditolak karena memalsukan opini dan menyusutkan variansi. (b) Membuang 77 baris: ditolak karena kolom harga, jumlah, dan total pada baris itu lengkap. (c) Menjadikan “Tidak diketahui” kategori kelima metode bayar: ditolak karena membuat perbandingan antar metode memuat kelompok yang bukan metode.
Dampak	Sel kosong bertambah 77. Rating kosong 46 baris (3,1%) setelah deduplikasi, metode_bayar kosong 28 baris. Rata-rata rating bergeser dari −27,72 menjadi 4,14.

Keputusan 6

Masalah	tanggal_transaksi memakai dua format (ISO pada 1.236 baris, DD/MM/YYYY pada 307 baris); total_bayar berupa teks “Rp 18.000” pada 250 baris.
Dugaan pola	Tidak berlaku.
Keputusan	Tanggal diurai menjadi datetime dengan format garis miring dibaca hari/bulan/tahun; awalan “Rp” dan titik ribuan dibuang sehingga total_bayar menjadi angka.
Alasan	Format garis miring pasti DD/MM: 186 dari 307 baris memiliki angka pertama lebih dari 12 dan tidak ada angka kedua yang lebih dari 12 (maksimum 11). Seluruh tanggal hasil urai jatuh pada 1 Agustus–28 November 2025. Titik pada “Rp 18.000” adalah pemisah ribuan, bukan desimal.
Alternatif ditolak	Membiarkan pengurai otomatis menebak: ditolak karena 121 tanggal ambigu (hari ≤ 12) akan terbaca bulan/hari terbalik tanpa peringatan.
Dampak	0 tanggal gagal diurai; 307 tanggal dan 250 nominal diformat ulang. Kolom bulan, hari, dan jam dapat diturunkan.

Keputusan 7

Masalah	Kosong pada berat_kg (351 baris, 22,7%), saldo_simpanan (159, 10,3%), catatan_kasir (1.044, 67,7%), dan id_transaksi (7 baris).
Dugaan pola	berat_kg MAR, saldo_simpanan MCAR (dugaan), catatan_kasir MNAR struktural, id_transaksi tidak diketahui (Bagian 3.1).
Keputusan	Dibiarkan kosong, tanpa imputasi dan tanpa membuang baris; ditambahkan kolom berat_tersedia.
Alasan	Kekosongan berat_kg pada Jasa dan Pulsa bermakna: tidak ada barang untuk ditimbang. Untuk ATK, kosong bergantung pada jumlah dan berat berkorelasi dengan jumlah (r = 0,67). Saldo_simpanan berubah dari transaksi ke transaksi (rata-rata 5,2 nilai berbeda per anggota), sehingga tidak ada nilai tetap per anggota untuk disalin. catatan_kasir kosong berarti tidak ada catatan.
Alternatif ditolak	(a) Imputasi median berat per produk: ditolak karena mengisi berat pada layanan tak berwujud dan meratakan hubungan jumlah–berat. (b) Imputasi saldo dengan median per anggota: ditolak karena menghapus perubahan saldo antar transaksi. (c) Membuang baris dengan kosong: ditolak karena membuang lebih dari seperempat data yang kolom lainnya lengkap.
Dampak	Tidak ada baris hilang. Analisis berat_kg terbatas pada 1.158 baris (77,2%) dan saldo_simpanan pada 1.343 baris (89,5%); batasan ini dinyatakan di Bagian 6.

Keputusan 8

Masalah	Fotokopi A4 (layanan) berkategori ATK (62 baris); berat_kg tidak mencerminkan berat produk; catatan "Promo mingguan" tidak sejalan dengan diskon_persen (58 dari 62 baris berdiskon 0%).
Dugaan pola	Tidak berlaku (masalah akurasi, bukan kekosongan).
Keputusan	Tidak diubah; dicatat di cleaning log dan sebagai pertanyaan untuk pemilik data.
Alasan	Data tidak memuat dasar untuk menetapkan jawaban yang benar. Memindahkan Fotokopi A4 ke Jasa, atau mengabaikan berat_kg, adalah keputusan definisi yang menjadi wewenang pemilik data.
Alternatif ditolak	Memindahkan Fotokopi A4 ke Jasa: ditolak sementara karena kategori aslinya konsisten pada seluruh 62 baris dan mungkin sengaja mengikuti pembukuan koperasi.
Dampak	Analisis per kategori harus menyebut bahwa ATK memuat jasa fotokopi (sekitar seperlima baris ATK). berat_kg tidak dipakai untuk kesimpulan fisik sampai maknanya terkonfirmasi.

5. Dampak pembersihan terhadap data

5.1 Sebelum dan sesudah

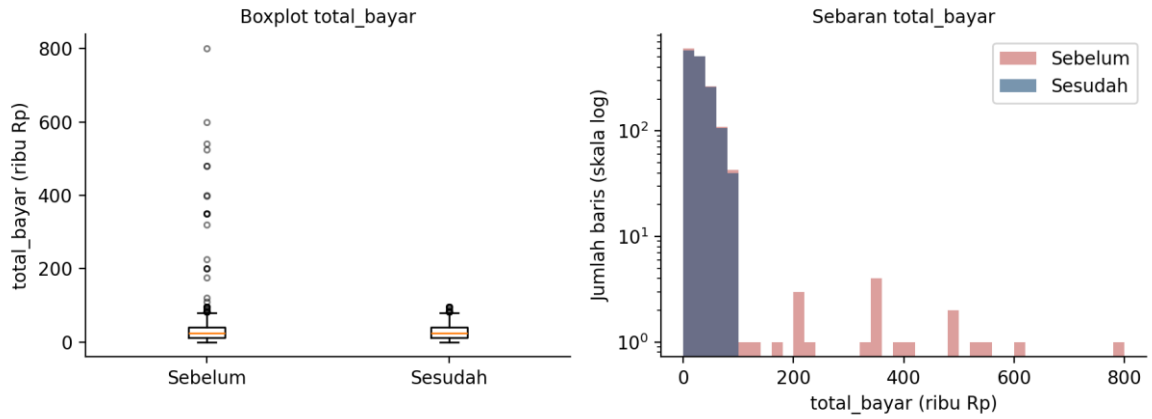
Ukuran	Sebelum	Sesudah	Catatan
Jumlah baris	1.543	1.500	Turun 43 baris: ID ganda dibuang (Keputusan 3).
Jumlah kolom	16	24	Naik 8 kolom: total_bayar_asli, jumlah_dikoreksi, diskon_dikoreksi, total_dikoreksi, berat_tersedia, bulan, hari, jam.
Total sel kosong	1.561	1.589	Naik 28. Sebanyak 77 sel placeholder (rating −999: 49; metode_bayar: 28) kini mengaku kosong; 49 sel kosong hilang bersama baris duplikat. Tanpa catatan_kasir: 517 menjadi 580.
Baris duplikat	24 (persis); 43 (menurut id_transaksi)	0	Penyeragaman kasir dilakukan sebelum deduplikasi agar duplikat berbeda huruf ikut terdeteksi.
Jumlah kategori pada kolom kunci	kategori: 18; metode_bayar: 13; kasir: 8	kategori: 5; metode_bayar: 4; kasir: 4	Penulisan baku; metode_bayar ditambah nilai kosong 28 baris.
Nilai unik pada kolom identitas	id_anggota: 318;	id_anggota: 259;	318 menjadi 259 karena spasi; id_transaksi unik tetap 1.493 (7 baris tanpa id).

Ukuran	Sebelum	Sesudah	Catatan
	id_transaksi: 1.493	id_transaksi: 1.493	

Kenaikan sel kosong bukan tanda pembersihan yang gagal: placeholder yang tadinya menyamar sebagai angka kini dicatat apa adanya sebagai kosong.

5.2 Dampak terhadap sebaran

Kolom	Mean sebelum	Mean sesudah	Pergeseran	Penilaian
total_bayar (Rp)	32.872	28.568	−4.304 (−13,1%)	Pergeseran besar dan memang disengaja. Median tetap 24.000, sehingga transaksi tipikal tidak berubah; simpangan baku turun dari 46.834 menjadi 20.219. 20 baris berlipat 10× menyumbang Rp7,17 juta dari omzet mentah dan menarik rata-rata ke atas.
jumlah (unit)	4,12	4,24	0,13 (+3,1%)	Pergeseran kecil. Median sama (4) dan simpangan baku 2,58 menjadi 2,40; nilai negatif dan nol hilang tanpa mengubah bentuk sebaran 1–8.
rating_layanan	−27,72	4,14	31,86	Pergeseran sangat besar karena −999 terbaca sebagai angka. Median sama (4); simpangan baku 175,96 menjadi 0,75. Tanpa penanganan, rata-rata rating tidak dapat ditafsirkan.



Gambar 1. total_bayar sebelum dan sesudah pembersihan (skala log pada histogram). Nilai ekstrem di atas Rp100.000 pada data mentah seluruhnya hasil kelipatan 10×.

6. Keterbatasan

- Data yang tidak dapat dipulihkan: berat_kg kosong pada 342 baris (22,8%) dan saldo_simpanan pada 157 baris (10,5%); rating_layanan pada 46 baris dan metode_bayar pada 28 baris. Analisis berat hanya berlaku untuk Makanan, Minuman, dan ATK dengan jumlah ≥ 3 sehingga tidak mewakili transaksi kecil (bias seleksi); analisis saldo hanya pada 89,5% baris.
- Dugaan MNAR yang tidak dapat dibuktikan: bila saldo_simpanan kosong karena saldo anggota rendah, rata-rata saldo kami terlalu besar. Bila pelanggan yang tidak puas lebih sering tidak memberi rating, rata-rata rating 4,14 terlalu besar. Bila kasir tidak mencatat hal yang sebenarnya terjadi, frekuensi catatan (misalnya “Pelanggan tetap”) terlalu kecil.
- Pemeriksaan yang belum dilakukan: pencocokan dengan struk atau pembukuan koperasi, pencocokan id_anggota dengan daftar anggota, dan verifikasi makna berat_kg serta saldo_simpanan karena tidak ada kamus data. Uji MCAR formal tidak dijalankan.
- Asumsi yang perlu dikonfirmasi ke pemilik data: format garis miring adalah DD/MM; pada 52 baris yang tidak cocok, total_bayar yang salah, bukan jumlah (pada 12 baris berlipat 2× kebalikannya secara teori mungkin); tanda minus pada jumlah adalah salah ketik; “Alat Tulis” sama dengan ATK; diskon sah hanya 0, 5, dan 10 persen; satu baris adalah satu item transaksi.
- Dampak pada kesimpulan: total omzet turun 15,5% setelah pembersihan, sehingga angka omzet dari data mentah tidak boleh dipakai; 52 total yang dihitung ulang berpotensi keliru bila asumsi di atas salah, karena itu hasil nanti perlu diuji dengan dan tanpa baris tersebut.

7. Penanganan data pribadi

Butir	Keterangan
Kolom data pribadi pada data olahan	id_anggota (pengenal AGT#### yang mengaitkan 259 anggota dengan riwayat transaksinya); saldo_simpanan (data keuangan per anggota); kasir (nama depan petugas); gabungan tanggal_transaksi (sampai menit) dengan id_anggota yang dapat mengungkap kebiasaan belanja. Tidak ada nama lengkap, NIK, kontak, atau alamat.
Tindakan penanganan yang diterapkan	Data mentah hanya dibaca dan tidak diubah; pembersihan dikerjakan pada salinan dan hasilnya ditulis ke data/processed/. Tidak ada penggabungan dengan sumber lain dan id_anggota hanya dirapikan (spasi), tidak ditautkan ke identitas.
Nilai k pada data yang diunggah	Tidak ada atribut demografis sehingga k klasik tidak dapat dihitung. Menurut id_anggota, kelompok terkecil adalah 1 transaksi (rata-rata 5,8), jadi pada level anggota k = 6.
Status repositori (publik atau privat)	Publik
data/raw/ masuk .gitignore	Ya

8. Langkah berikutnya

- Konfirmasi ke pemilik data: apakah total_bayar atau jumlah yang benar pada 52 baris yang tidak cocok; arti dan satuan berat_kg (dan mengapa kosong pada ATK berjumlah 1–2); apakah saldo_simpanan dicatat sebelum atau sesudah transaksi.
- M3 (notebook EDA tahap 1): sebaran omzet per kategori, bulan, jam, dan metode bayar; hubungan diskon dengan jumlah; rating per kasir dan kategori dengan memperlakukan rating kosong secara eksplisit.

- Uji sensitivitas: ulangi analisis utama dengan dan tanpa 52 baris yang total_bayar-nya dihitung ulang untuk melihat apakah kesimpulan berubah.
- Tetapkan keputusan kategori Fotokopi A4 (ATK atau Jasa) bersama pemilik data atau dosen.
- Bungkus pembersihan dalam satu fungsi di notebook (clean_koperasi.py), jalankan Restart and run all, lengkapi README provenans, dan jalankan python cek_m2.py.

Lampiran A — Cleaning log

#	Langkah	Baris terdampak	Alasan
1	Perbaiki tipe data	307 tanggal DD/MM; 250 total “Rp …”	Dua format tanggal dan nominal teks membuat urutan waktu dan penjumlahan salah. DD/MM dipastikan karena 186 baris punya angka pertama > 12 dan tidak ada angka kedua > 12.
2	Buang spasi kolom teks	id_anggota 65 sel; kategori 59; metode_bayar 36	Spasi memecah 259 anggota menjadi 318 nilai dan menggandakan kategori; dibuang sebelum penyeragaman agar pemetaan tidak perlu menampung varian spasi.
3	Placeholder menjadi kosong	rating −999: 49; metode_bayar placeholder: 28	−999 dan “null/N/A/-/tidak diketahui” bukan nilai sah; rating −999 membuat rata-rata −27,7. Dijadikan kosong, tidak diisi, agar tidak menciptakan opini atau metode.
4	Seragamkan kategori	kategori 121 sel; metode_bayar 95; kasir 19	Peta manual (Lampiran B). “Alat Tulis” digabung ke ATK karena memuat empat produk yang sama persis. Dilakukan sebelum deduplikasi agar “rina” dan “Rina” dikenali sebagai baris yang sama.
5	Tangani duplikat	43 baris dibuang (42 ID ganda)	Semua kolom selain catatan_kasir identik pada ID ganda. Dipertahankan baris dengan catatan terisi. 7 baris tanpa id tidak dianggap duplikat.
6	Tangani nilai mustahil	jumlah 29; diskon 9; total_bayar 52	Dipulihkan dari total_bayar bila cocok (16 dari 18 negatif; 11 dari 11 nol; 9 dari 9 diskon); total_bayar dihitung ulang bila tidak cocok (0,5×: 20; 2×: 12; 10×: 20) karena harga per produk tetap. Nilai lama disimpan.
7	Tangani nilai kosong	berat_kg 342; saldo 157; catatan 1.009; rating 46; metode 28; id 7	Tidak diisi: berat_kg tidak bermakna pada Jasa/Pulsa dan bergantung jumlah pada ATK; saldo berubah antar transaksi; catatan kosong berarti tidak ada catatan. Ditambah kolom berat_tersedia.
8	Buat kolom turunan	1.500 baris	bulan, hari, jam dari tanggal untuk analisis waktu (M3), serta penanda total_dikoreksi, jumlah_dikoreksi, diskon_dikoreksi, dan total_bayar_asli agar setiap koreksi dapat diaudit.

Lampiran B — Peta keputusan manual

Nilai asal	Diubah menjadi	Dasar keputusan
kategori “Alat Tulis” (41 baris)	ATK	Memuat empat produk yang sama dengan ATK (Buku Tulis, Fotokopi A4, Map Plastik, Pulpen Hitam), tanpa produk lain.
kategori “Minumam” (22 baris)	Minuman	Salah ketik; produknya di baris lain selalu Minuman.
kategori MAKANAN, MINUMAN, JASA, PULSA (58 baris)	Makanan, Minuman, Jasa, Pulsa	Hanya beda huruf kapital; produk dan satuan identik dengan versi baku.
metode_bayar “Qris”, “qris” (53 baris)	QRIS	Beda kapitalisasi; metode yang sama.
metode_bayar “tunai” (30), “transfer” (7), “saldo koperasi” (5)	Tunai, Transfer, Saldo Koperasi	Beda kapitalisasi; metode yang sama.
kasir “rina”, “bagus”, “dimas”, “sari” (19 baris)	Rina, Bagus, Dimas, Sari	Nama yang sama dengan huruf kecil; tidak ada kasir bernama lain.
metode_bayar “-”, “null”, “N/A”, “tidak diketahui” (28 baris)	(kosong)	Bukan metode pembayaran; nilai sebenarnya tidak diketahui.
rating_layanan −999 (49 baris)	(kosong)	Kode “tidak ada penilaian”; rating sah hanya 2–5.
diskon_persen 110 (1), 150 (2), −20 (6)	10; 0; 0 (5 baris) atau 5 (1 baris)	Dipilih satu-satunya tingkat sah (0, 5, 10) yang cocok dengan total_bayar.
jumlah negatif (18) dan nol (11)	|jumlah|; total ÷ (harga × (1 − diskon))	16 dari 18 negatif cocok dengan total sebagai tanda salah; 11 dari 11 nol menghasilkan bilangan bulat 1–8.
total_bayar “Rp 18.000” (250 baris)	18000	Titik adalah pemisah ribuan.